ŽILINSKÁ UNIVERZITA
V ŽILINE

Fakulta bezpečnostného inžinierstva

Využitie a výhody strojového učenia pri odhaľovaní zneužitia vstupu v SKV

Semestrálna práca

Bc. Ján Trhan

Študijný program: Bezpečnostný manažment

Študijný odbor: Bezpečnostné vedy

Obsah

Úvod 1
1 Teoretické východiská 2
1.1 RFID technológia 2
1.2 Biometria a behaviorálne znaky 2
1.3 Strojové učenie 2
2 Návrh systému a prototypu 4
2.1 Cieľ systému 4
2.2 Použité dáta 4
2.3 Hodnotiace metriky 5
3 Experimentálna časť 6
3.1 Threshold-based detection 6
3.2 Testovanie algoritmov na detekciu anomálií 7
3.3 Dĺžka a rýchlosť priloženia 8
3.4 Porovnanie výsledkov 9
4 Prototyp 10
4.1 Výroba prototypu 10
4.2 Porovnanie reálnych dát 11
Záver 13

ÚVOD

V súčasnosti sú systémy kontroly vstupu bežnou súčasťou ochrany objektov, pričom najčastejšie využívajú **RFID technológiu** a rozhodovanie na základe identifikátora karty. Takýto prístup je rýchly, praktický a jednoducho nasaditeľný, no jeho slabinou je, že systém nevie rozlíšiť, či kartu používa jej **skutočný vlastník**, alebo **neoprávnená osoba**. V tejto práci zameriavam na možnosti rozšírenia klasického systému kontroly vstupu o **analýzu správania používateľa** pri samotnom vstupe.

Práca sa venuje využitiu metód **strojového učenia** pri odhaľovaní zneužitia vstupu v systémoch kontroly vstupu. Cieľom je overiť, či je možné na základe časových a behaviorálnych údajov, získaných počas jednej vstupovej udalosti, rozlíšiť bežný legitímny vstup od podozrivého alebo neoprávneného správania. Pozornosť je zameraná najmä na čas priloženia karty, dĺžku jej priloženia a priebeh priblíženia sa používateľa k čítačke, ktoré môžu vytvárať charakteristický profil správania konkrétnej osoby.

V teoretickej časti práce sú stručne spracované východiská **RFID technológie**, **biometrie** a **behaviorálnych znakov**, ako aj základné princípy **strojového učenia.** Praktická časť sa následne venuje návrhu datasetu, výberu hodnotiacich metrík a testovaniu viacerých prístupov na detekciu anomálií.

Súčasťou práce je aj vytvorenie **jednoduchého prototypu**, ktorý slúži na zber reálnych dát a na overenie, či navrhnutý prístup dokáže fungovať aj mimo experimentálneho prostredia. Výsledkom práce má byť zhodnotenie, do akej miery môžu metódy strojového učenia prispieť k zvýšeniu bezpečnosti vstupných systémov bez potreby zásahu používateľa navyše.

Dokumentácia, kód a materiály použité na zámery práce sú voľne dostupné na GitHub úložisku : https://github.com/OctyGap/rfid-anomaly-detection.git (2026-04-17)

1 TEORETICKÉ VÝCHODISKÁ

V tejto kapitole zhrniem teoretické poznatky, ktorými sa budem riadiť pri vyhotovaní práce

1.1 RFID technológia

Radio Frequency Identification (RFID) je forma bezdrôtovej komunikácie, ktorá využíva elektromagnetické vlny na **vyhľadávanie, identifikáciu, sledovanie a komunikáciu s objektmi a ľuďmi**. RFID tagy sú pasívne alebo aktívne. Pasívne využívajú energiu z čítačky a môžu byť čítané bez priameho kontaktu. V prístupových systémoch sa používajú najmä pasívne tagy v kombinácii s čítačkou, ktorá otvorí dvere, ak ID karty zodpovedá registrovanému používateľovi.[2]

1.2 Biometria a behaviorálne znaky

Identifikácia alebo verifikácia pomocou biometrie je vo všeobecnosti založená na štatistickom a analytickom prístupe. Ide o automatizovaný systém rozpoznávania ľudí, pomocou merateľných charakteristík. [1]

V práce bude využitá na **automatizovaný systém rozpoznávania ľudí**. Súčasné systémy umožnujú rozpoznávanie v čoraz viac odvetiach, ako napríklad rozpoznávanie očnej dúhovky, sietnice, a ďalších vlastností ktoré človek nedokáže využiť.[1]

Túto výhodu plánujem použiť na podporu rozpoznania charakteristík používateľa karty a rozpoznania jeho správania.

1.3 Strojové učenie

Strojové učenie predstavuje oblasť **umelej inteligencie**, ktorej cieľom je vytvárať **algoritmy schopné učiť sa** zo vstupných dát a následne robiť rozhodnutia alebo predikcie aj pre nové, predtým neznáme situácie. Na rozdiel od klasického programovania, kde sú pravidlá presne definované programátorom, pri strojovom učení sa model učí vzťahy a vzory priamo z dát. Práve táto vlastnosť robí strojové učenie vhodným pre úlohy, pri ktorých nie je možné jednoducho zapísať všetky pravidlá správania, napríklad pri rozpoznávaní anomálií, klasifikácii používateľov alebo predikcii budúcich hodnôt.[3]

Základný princíp fungovania je založený na tom, že model dostane **trénovacie dáta**, v ktorých hľadá opakujúce sa závislosti medzi jednotlivými znakmi. Počas učenia sa jeho vnútorné parametre postupne upravujú tak, aby model čo najlepšie vystihol pozorovaný

vzor. Po natrénovaní sa model testuje na **oddelenej** množine dát, ktoré počas učenia **nevidel**. Takýto postup je dôležitý preto, aby sa overilo, či model dokáže získané poznatky zovšeobecniť aj na **nové prípady** a nepracuje len s naučenými detailmi konkrétneho datasetu. V praxi teda proces zahŕňa prípravu dát, výber príznakov, trénovanie modelu, vyhodnotenie výsledkov a následnú interpretáciu.[3]

Dôležitou výhodou strojového učenia je **schopnosť pracovať s väčším množstvom príznakov naraz.** Kým jednoduchý pravidlový systém býva založený na pevne nastavených limitoch, napríklad na tom, že používateľ vstupuje len v určitom čase, model strojového učenia dokáže vyhodnocovať viacero faktorov súčasne. Vďaka tomu môže byť presnejší a citlivejší na jemné odchýlky. Súčasne však treba počítať s tým, že **kvalita modelu je priamo závislá od kvality dát.** Ak sú dáta neúplné, skreslené alebo príliš malé, model môže robiť chybné rozhodnutia. Preto je pri návrhu riešenia nevyhnutné správne pripraviť dataset, zvoliť vhodné príznaky a výsledky overovať na samostatných testovacích dátach.[4]

2 NÁVRH SYSTÉMU A PROTOTYPU

V tejto kapitole sa ujasním, čo presne má systém robiť, z akých dát vychádzam a podľa čoho budem hodnotiť, či je vstup normálny alebo podozrivý. Zameriavam sa hlavne na to, ako sa dá klasický RFID prístup rozšíriť o jednoduchú analytickú vrstvu, ktorá vie zachytiť aj správanie používateľa pri vstupe.

2.1 Cieľ systému

Systém bude zameraný na rozšírenie bežnej kontroly vstupu na sofistikovanejšie spracovanie dát pomocou knižníc strojového učenia v programovacom jazyku python. Bežný prístupový systém rozhoduje najmä podľa identifikátora karty. Takýto prístup je rýchly a praktický, ale nedokáže rozlíšiť, či kartu používa jej skutočný vlastník, alebo iná osoba, ktorá sa ku karte dostala. Navrhované riešenie sa preto zameriava na doplnenie klasickej identifikácie o analýzu **charaktericstických znakov** používateľa.

Systém má pracovať s údajmi, ktoré je možné získať počas jednej vstupovej udalosti bez toho, aby bolo potrebné používateľa **zaťažovať** ďalšou **činnosťou**, napr. dĺžka času, počas ktorej používateľ držal kartu na čítačke. Predpokladom návrhu je, že spôsob, akým konkrétny človek pristupuje ku čítačke a používa kartu, **nie je úplne náhodný**. Naopak, pri dlhodobejšom sledovaní sa v ňom objavujú určité **opakujúce sa vzory**.

2.2 Použité dáta

Pri návrhu a testovaní systému som pracoval s dvoma syntetickými datasetmi vo formáte CSV. Datasety boli vygenerované pomocou **nástroja ChatGPT 5.4 – Extended Pro model**. Model použil **reálne záznamy** vstupov na internát, voľne stiahnuteľné z internetu a doplnil to o **jednoznačne oddeľujúce dáta dĺžky** a rýchlosti priloženia karty, ktoré sám vygeneroval.

Prvý dataset predstavuje **bežné vstupy legitímneho používateľa** a slúži ako základ pre trénovanie a vytvorenie referenčného profilu správania. Druhý dataset obsahuje testovacie údaje, ktoré reprezentujú **podozrivé alebo odlišné vstupy** a používam ho na overenie, či systém vie takéto prípady rozpoznať. Vstupy zaznamenané v druhom datasete boli vygenerované tak, aby šlo o pokusy o útok vo viacerých časoch, vrátane rutín z prvého datasetu.

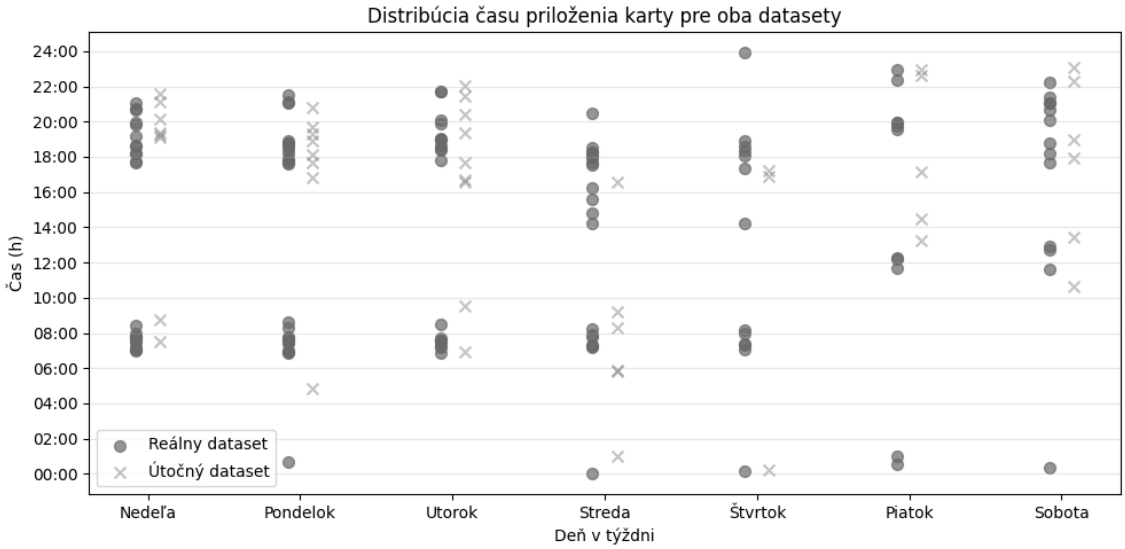

Obrázok 1 - Znázornenie dát

Pre použitím je dáta ešte potrebné upraviť do formy **vhodnej pre algoritmy**. Dáta musia byť úplné, nesmú obsahovať **prázdne hodnoty** a musia sa **zhodovať**. Keďže dáta sú z veľkej časti syntetické, tento krok nebol problém.

Potom je potrebné upraviť ich tak aby ich algoritmus vedel optimálne využiť. To môže znamenať napríklad preformátovanie času z 24h formátu na **počet sekúnd od nuly**. Pri takýchto údajoch majú **krajné hodnoty** v skutočnosti blízko k sebe, napríklad nedeľa a pondelok alebo čas 23:59 a 00:00.

Osobitne som upravill aj údaje o dĺže a rýchlosti priloženia karty.

2.3 Hodnotiace metriky

Na vyhodnotenie úspešnosti navrhnutého riešenia som použil dve základné metriky.

FRR, teda False Rejection Rate, vyjadruje podiel prípadov, keď systém nesprávne odmietne legitímneho používateľa. V mojom prípade ide o situáciu, keď je bežný vstup vlastníka vyhodnotený ako podozrivý alebo anomálny. Táto metrika je dôležitá hlavne z pohľadu použiteľnosti systému, pretože vysoká hodnota znamená, že systém je príliš prísny.

FAR, teda False Acceptance Rate, vyjadruje podiel prípadov, keď systém nesprávne akceptuje neoprávnený vstup. V tejto práci ide o situáciu, keď vstup, ktorý sa správaním nezhoduje s profilom vlastníka, systém vyhodnotí ako normálny. Táto metrika je kľúčová z pohľadu bezpečnosti, pretože ukazuje, ako často vie podozrivá udalosť prejsť bez zachytenia.

Dôležité je, aby systém vedel zachytiť podozrivé vstupy a zároveň neodmietal bežného používateľa.

3 EXPERIMENTÁLNA ČASŤ

V tejto kapitole sa zameriavam na samotné testovanie navrhnutého riešenia. Cieľom je overiť, či je možné na základe pripravených dát rozlíšiť bežný vstup od podozrivej udalosti.

Z dát vyplýva, že sledovaný subjekt prikladá kartu pomerne **pravidelne**, v čase okolo 8:00 a 18:00 každý deň. Vyskutujú sa však **odchýlky**. Sú rôzne spôsoby ako v tejto situácii **odhaliť zneužitie vstupu**, medzi najintuitívnejšie a najjednudichšie by som zaradil :

> **Rule-based detection** - pevné pravidlá typu: vstup mimo 7:00–9:00 a 17:00–20:00 = podozrivé
>
> **Threshold-based detection** - ak sa čas priloženia odchýli od normálu o viac než limit, označí sa to

Použijem teda treshold-based detection, toto bude môj kontrolný algoritmus, pokiaľ by strojové učenie nedokázalo doručiť **lepšie výsledky**, nemá logický zmysel ho použiť.

3.1 Threshold-based detection

Testovanie som vykonal pre tri rôzne prahy, a to ±1 hodina, ±2 hodiny a ±5 hodín. Ak sa vstup nachádzal mimo zvoleného intervalu, bol označený ako anomália. Ak zostal v jeho rámci, systém ho považoval za normálny.

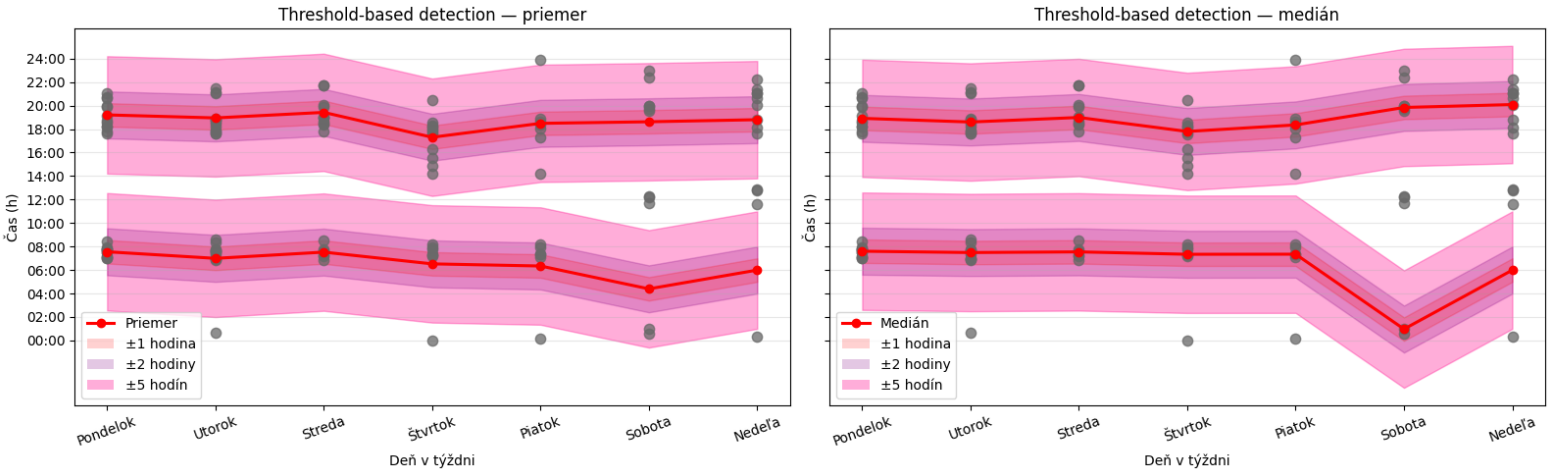

Obrázok 2 - Porovnanie odchýlky, priemer a medián

Tento prístup ukázal, že pri úzkom prahu častejšie odmieta aj legitímne vstupy. Naopak pri širšom prahu rastie riziko, že ako normálny vyhodnotí aj podozrivý vstup.

Threshold-based detection preto potvrdzuje, že samotný čas vstupu nestačí na presnejšie rozlišovanie správania používateľov.

Interpretácia výsledkov

Tabuľka 1 - Interpretácia výsledkov algoritmu odchýlky

METRIKA	ODCHÝLKA ±1H:	ODCHÝLKA ±2H:	ODCHÝLKA ±5H:
FRR	28.95% (11/38)	10.53% (4/38)	2.63% (1/38)
FAR	26.67% (12/45)	60.00% (27/45)	86.67% (39/45)

Z testovania vyplýva že algoritmus je **najúčinejší** pri odchýlke na 1h. Výsledky tohto nastavenia teda budem používať ako **základné hodnoty**, ktoré by strojové učenie malo prekonať. ***FAR 26.67% FRR 28,95%***

3.2 Testovanie algoritmov na detekciu anomálií

V tejto časti som sa zameral na modely určené na detekciu anomálií. Nepracoval som len s jedným modelom, ale najskôr som otestoval viac prístupov.

Medzi testované algoritmy patril **One-Class SVM**, **Local Outlier Factor**, **Elliptic Envelope** a **Isolation Forest**.

One-Class SVM vytvára hranicu normálneho správania a sleduje, či sa nové dáta nachádzajú ešte v tomto priestore alebo už mimo neho.

Local Outlier Factor hodnotí, či sa daný bod správa podobne ako jeho okolie, alebo je od neho výraznejšie odlišný.

Elliptic Envelope vychádza z predpokladu, že bežné dáta majú približne kompaktné rozloženie, a odľahlé body vyhodnocuje ako anomálie.

Isolation Forest namiesto hľadania jednej spoločnej hranice sa snaží anomálne body izolovať, tie sa zvyčajne oddeľujú rýchlejšie než bežné dáta.

Tabuľka 2 - Interpretácia výsledkov algoritmov strojového učenia pri použití len času

ALGORITMUS	FRR (%)	FAR (%)	CHYBNÉ ODMIETNUTIA	CHYBNÉ PRIJATIA
ISOLATION FOREST	36.84	35.56	14	16
ONE-CLASS SVM	21.05	46.67	8	21
LOCAL OUTLIER FACTOR	26.32	71.11	10	32
ELLIPTIC ENVELOPE	44.74	77.78	17	35

Isolation Forest

Najlepšie výsledky v testovaní dosiahol algoritmus Isolation Forest. Nastavanie neboli úplne optimálne, pretože sa jedná len o prvotné testovanie algoritmov a ešte nie sú zahrnuté všetky príznaky. Algoritmus sa teda pokúšal rozoznať anomálie len na základe času vstupov. Z výsledkov vyplýva že samotné údaje vstupu nebudú stačiť na dobrý algoritmus, pri tak slabých údajoch algoritmus ani nedokáže konkurovať najprimitívnejším metódam.

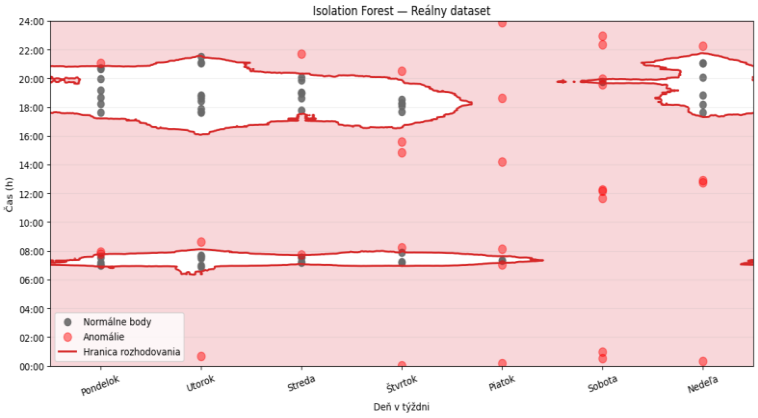

Obrázok 3 - Isolation forest - Reálny dataset

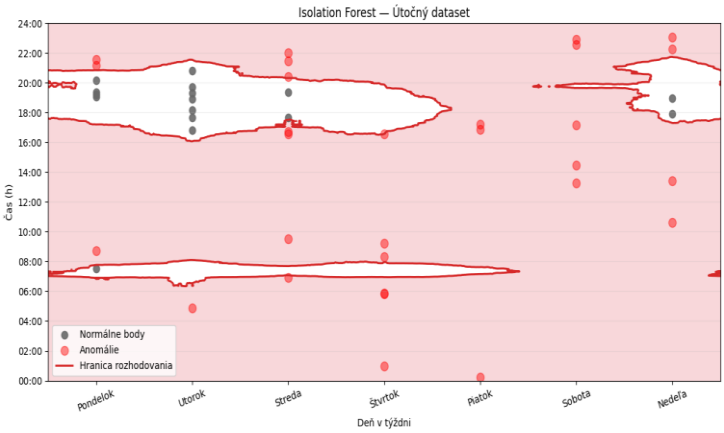

Obrázok 4 - Isolation forest - Útočný dataset

3.3 Dĺžka a rýchlosť priloženia

Okrem času vstupu som sa zameral aj na dĺžku priloženia RFID karty a na rýchlosť priblíženia sa k čítačke. Tieto údaje lepšie vystihujú samotný priebeh vstupovej udalosti.

Pri zohľadnení týchto charakteristík som znova vyskúšal úspešnosť už použitých 4 algoritmov

Tabuľka 3 - Interpretácia výsledkov algoritmov strojového učenia pri použití ostatných príznakov

ALGORITMUS	FRR (%)	FAR (%)	CHYBNÉ ODMIETNUTIA	CHYBNÉ PRIJATIA
ELLIPTIC ENVELOPE	7.89	0.00	3	0
ONE-CLASS SVM	23.68	2.22	9	1
LOCAL OUTLIER FACTOR	10.53	13.33	4	6
ISOLATION FOREST	13.16	26.67	5	12

3.4 Porovnanie výsledkov

Pri porovnaní výsledkov sa ukázalo, že samotný čas vstupu nie je dostatočný príznak na spoľahlivé rozlíšenie legitímneho a podozrivého správania. Potvrdilo sa to už pri threshold-based detection, kde najlepšie výsledky dosiahla odchýlka ±1 hodina, no aj pri tomto nastavení ostali hodnoty **FAR 26.67 %** a **FRR 28.95 %**. Takýto výsledok je použiteľný len ako veľmi jednoduchý základ, nie ako riešenie.

Po rozšírení vstupov o **dĺžku priloženia karty** a **rýchlosť priblíženia sa k čítačke** som dosiahol výborné výsledky. Po doplnení týchto príznakov sa výsledky všetkých algoritmov zlepšili, pričom najlepšie hodnoty dosiahol **Elliptic Envelope**, kde bola hodnota **FRR 7.89 %** a **FAR 0.00 %**. Oproti tomu Isolation Forest už pri rozšírených príznakoch nedosiahol najlepší výsledok, aj keď sa stále ukázal ako použiteľný model.

Na základe testovania môžem konštatovať, že strojové učenie má v tejto problematike zmysel až vtedy, keď pracuje s vhodne zvolenými vstupnými údajmi. Ak by systém vychádzal len z času vstupu, jednoduchý threshold-based prístup by bol porovnateľný alebo dokonca vhodnejší. Po doplnení behaviorálnych príznakov však modely strojového učenia dosiahli výrazne lepšie výsledky.

4 PROTOTYP

Výsledky ukázali, že samotný princíp je použiteľný, no zároveň aj to, že bez reálnych dát nie je možné robiť silné závery o správaní systému v praxi. Syntetické dáta síce vedia dobre poslúžiť pri návrhu a ladení modelu, ale nedokážu úplne nahradiť prirodzenú variabilitu reálneho správania používateľov. Práve preto bude ďalším krokom získanie reálnych meraní.

4.1 Výroba prototypu

Na overenie navrhnutého riešenia bol vytvorený jednoduchý hardvérový prototyp postavený na mikrokontroléri **ESP32**. Ako hlavná riadiaca jednotka bol zvolený práve tento modul, pretože je lacný, ľahko dostupný a zároveň ponúka dostatočný výkon aj potrebné komunikačné rozhrania pre pripojenie viacerých senzorov. Na identifikáciu RFID karty bol použitý modul **PN532**. Na meranie vzdialenosti bol použitý senzor **VL53L0X**, ktorý pracuje na princípe Time of Flight.

Zapojenie bolo realizované tak, aby bolo možné súčasne čítať RFID kartu aj zaznamenávať vzdialenosť pri priblížení.

Cieľom výroby prototypu **nebolo** vytvoriť finálne **zariadenie pripravené** na **nasadenie**, ale **funkčný** model, na ktorom je možné overiť zber dát a základnú logiku navrhnutého riešenia. Prototyp tak slúži najmä ako praktický základ pre ďalšiu fázu práce, v ktorej bude nasledovať získavanie reálnych meraní a ich vyhodnotenie. Rovnobežne tak bol venovaný aj čas zapojenia prototypu.

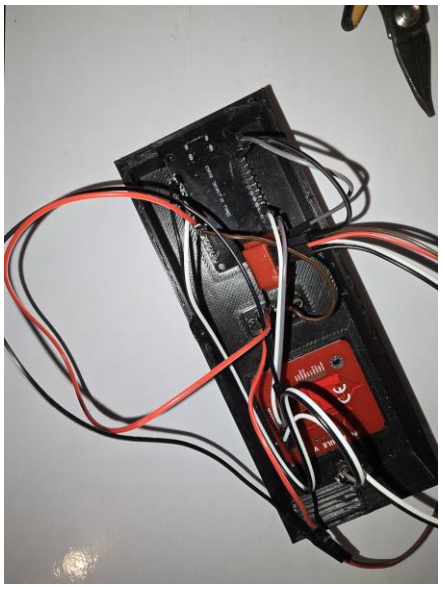

Obrázok 5 - Zapojenie prototypu

Zariadenie bolo následne nasadené v laboratórnych podmienkach a testované mňou a ďalšou osobou. Osoba mala, tak isto aj ja sme prikladali kartu prirodzene. Treba však zohľadniť aj podmienky merania. Pri opakovanom prikladaní karty mohla u oboch subjektov postupne nastať mierna únava, čo mohlo ovplyvniť prirodzenosť pohybu.

Dáta boli merané na 30 vzorkách, ktoré potom boli rovnomerne použité v pôvodnom datasete vstupov. Takýto počet dát nemusí byť dostačujúci a preto to neodráža skutočné podmienky v reálnom prostredí. Stále sú to ale cenné poznatky oproti syntetickým dátam.

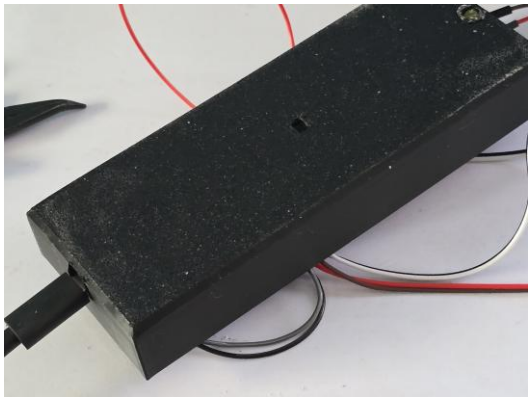

Obrázok 6 - Pripravený prototyp

4.2 Porovnanie reálnych dát

Pri vyhodnotení reálnych meraní sa ukázalo, že najlepší výsledok nemal samotný čas vstupu ani jednotlivé klasické algoritmy. One-Class SVM síce znížil hodnotu FAR na 15,56 %, no zároveň dosiahol FRR 47,37 %, čo je z pohľadu použiteľnosti systému príliš vysoká hodnota.

Tabuľka 4 - Interpretácia výsledkov algoritmov strojového učenia na reálnom datasete

ALGORITMUS	FRR (%)	FAR (%)	CHYBNÉ ODMIETNUTIA	CHYBNÉ PRIJATIA
ONE-CLASS SVM	47.37	15.56	18	7
ELLIPTIC ENVELOPE	21.05	62.22	8	28
ISOLATION FOREST	26.32	73.33	10	33
LOCAL OUTLIER FACTOR	5.26	95.56	2	43

Neurónová sieť

Pri zlyhaní všetkých testovaných algoritmoch na reálnych dátach som sa pokúsil použiť aj neurónovú sieť. Tento algoritmus strojového učenia je považovaný za jeden z najsilnejších a najprispôsobivejších a používaný ako základ všetkých komplexnejších

riešení. Jeho nevýhodou je ale výpočtová náročnosť, co v tomto projekte neznamená problém.

Autoencoder dosiahol FRR 15,79 % a FAR 28,89 %, teda zlepšil najmä mieru chybných odmietnutí, ale ešte neposkytol dostatočne presný výsledok z pohľadu bezpečnosti.

Ako finálny model bol preto zvolený fúzovaný autoencoder, ktorý spája časové príznaky a ToF príznaky správania pri priložení karty, ale zároveň **nastaví** hodnotám **váhu**. Vo finálnom skóre **mala vyššiu váhu behaviorálna** vetva, pretože lepšie opisuje samotný pohyb pri vstupe, zatiaľ čo **čas vstupu** slúži skôr ako **doplnkový** kontext. Tento model dosiahol FRR 2,63 %, čo predstavuje 1 chybne odmietnutý legitímny vstup z 38, a FAR 6,67 %, teda 3 chybne akceptované neoprávnené vstupy zo 45.

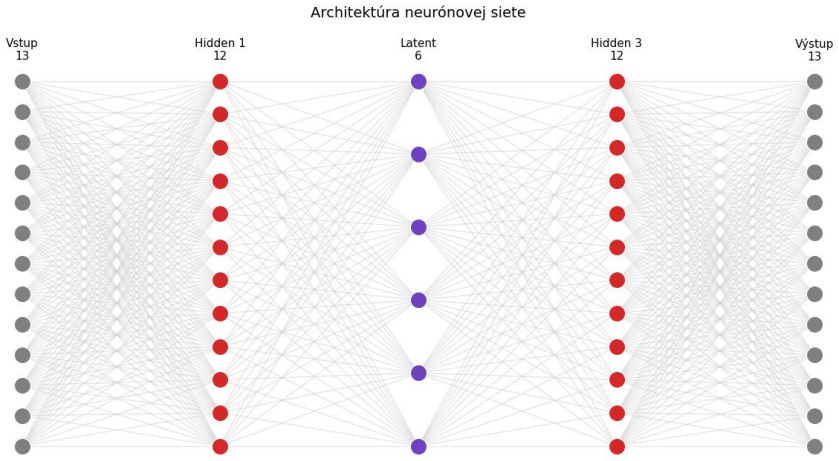

Obrázok 7 - Architektúra NN

V porovnaní s threshold-based prístupom pri odchýlke ±1 hodina sa tak počet chybných odmietnutí znížil z 11 na 1 a počet chybných akceptácií z 12 na 3.

ZÁVER

Výsledky práce ukázali, že využitie strojového učenia pri odhaľovaní zneužitia vstupu v SKV má zmysel až vtedy, keď model pracuje s vhodne zvolenými príznakmi. Pri použití samotného času vstupu boli výsledky jednoduchých prístupov aj klasických algoritmov detekcie anomálií nevyrovnané a z pohľadu praktického nasadenia nedostatočné. Po doplnení behaviorálnych údajov zo senzora Time of Flight a dĺžky pridržania karty sa však presnosť vyhodnotenia výrazne zlepšila.

Najlepší výsledok dosiahol fúzovaný autoencoder, ktorý na reálnych meraniach dosiahol **FRR 2,63 % a FAR 6,67 %.** Takýto výsledok ukazuje, že neinvazívna analýza priebehu priloženia RFID karty môže predstavovať **vhodné doplnenie klasickej identifikácie**. Zároveň však treba zohľadniť, že merania prebehli v laboratórnych podmienkach a na malej vzorke používateľov

Na základe dosiahnutých výsledkov možno konštatovať, že strojové učenie má pri systémoch kontroly vstupu **praktický prínos**, avšak iba za predpokladu kvalitného návrhu vstupných príznakov a overenia modelu na dostatočne rozsiahlych reálnych dátach.

Do budúcna by som ešte uvažoval o testovaní rýchlosti vyhodnotenia priamo na zariadení ESP alebo čipe STM32 a využiteľnosti bez výpočtu na externom hardvéry.

Zoznam použitej literatúry

[1] **BOROŠ, Martin; VEĽAS, Andrej; LENKO, Filip a Radoslav KUFFA**. Elektronické systémy kontroly vstupov. Žilina: EDIS – vydavateľstvo Žilinskej univerzity v Žiline, 2023. ISBN 978-80-554-2036-3.

[2] **GEEKSFORGEEKS**. Introduction of Radio Frequency Identification (RFID). Online. Dostupné na: https://www.geeksforgeeks.org/computer-networks/introduction-of-radio-frequency-identification-rfid/. zobrazené 2026-04-14.

[3] **IBM. What is Machine Learning?** Online. Dostupné na: https://www.ibm.com/think/topics/machine-learning zobrazené 2026-04-17.

[4] **MICROSOFT**. Introduction to Machine Learning Concepts. Online. Dostupné na: https://learn.microsoft.com/en-us/training/modules/fundamentals-machine-learning/. zobrazené 2026-04-14.

[5] **SCIKIT-LEARN**. Novelty and Outlier Detection. Online. Dostupné na: https://scikit-learn.org/stable/modules/outlier_detection.html. zobrazené 2026-04-14.

[6] **maxin-nk. Identification_of_Poor_Students.** Online. GitHub. Dostupné na: https://github.com/maxin-nk/Identification_of_Poor_Students. zobrazené 2026-04-17.